Universidad Nacional De La Matanza
Especialización en Ciencia de Datos

Seminario de Procesamiento de Lenguaje Natural
Profesor: Caiafa, Marcelo

Trabajo Práctico Integrador
Sistema de Recuperación y Comprensión de Normativa SENASA

Integrantes Grupo 2:

Fica Millán, Yesica
Petraroia, Franco

- Año 2026 –

Contenido

1. Introducción 4

1.1 Definición del Problema 4

1.2 Objetivo y relevancia 4

2. Metodología 4

2.1 Construcción y Análisis del Corpus 4

Fuentes y características 4

2.2 Preprocesamiento 5

Extracción de texto (pdf_loader.py) 5

Segmentación en chunks (chunker.py) 5

3. Modelado 6

3.1 Modelo clásico: TF-IDF + similitud coseno 6

3.2 Modelo profundo: embeddings semánticos + FAISS 6

3.3 Modelo híbrido: interpolación lineal 7

3.4 Módulo de pregunta-respuesta (QA) 8

4. Comparación de Modelos 8

Protocolo de evaluación 8

Gold standard 9

4.1 Resultados de retrieval 9

4.2 Resultados por tipo de query 9

4.3 Resultados de QA 10

4.4 Resultados de QA - RAG DistilBERT 10

4.5 Interpretación lingüística 10

5. Implementación 11

5.1 Arquitectura del sistema 11

5.2 API REST 11

5.3 Reproducibilidad 11

6. Discusión 12

6.1 Alineación con objetivos organizacionales 12

6.2 Ética y mitigación de sesgos 12

6.3 Limitaciones 12

7. Conclusiones 13

Anexos 14

Anexo I 14

Anexo II 14

Anexo III 15

Anexo IV 16

Anexo V 17

1. Introducción

1.1 Definición del Problema

El Servicio Nacional de Sanidad y Calidad Agroalimentaria (SENASA) emite de forma continua resoluciones que regulan diversos aspectos de la producción agropecuaria en Argentina, incluyendo la sanidad animal, la trazabilidad y el control de enfermedades como la brucelosis bovina.

Estos documentos presentan una elevada complejidad estructural y lingüística, ya que combinan considerandos legales con especificaciones técnicas. Como consecuencia, su consulta e interpretación resultan difíciles para productores, veterinarios y otros actores del sector, especialmente cuando se requiere acceder rápidamente a información puntual.

El desafío principal radica en la naturaleza del lenguaje normativo, donde la precisión léxica es tan importante como la comprensión del contexto semántico. En este tipo de textos, pequeñas variaciones en la terminología pueden implicar diferencias significativas en la interpretación legal.

Este trabajo propone un sistema automatizado de recuperación y comprensión de normativa SENASA basado en técnicas de Procesamiento del Lenguaje Natural (NLP). El sistema permite realizar consultas en lenguaje natural y obtener respuestas con trazabilidad directa hacia el documento fuente, combinando recuperación de información (IR) con modelos de pregunta-respuesta (QA).

1.2 Objetivo y relevancia

El objetivo principal es diseñar, implementar y evaluar un pipeline NLP end-to-end que permita:

- Recuperar fragmentos relevantes de resoluciones SENASA ante consultas en lenguaje natural.
- Generar respuestas con trazabilidad hacia el documento y artículo fuente.
- Comparar el desempeño de un enfoque clásico (TF-IDF) con un enfoque profundo (embeddings semánticos y BERT) en el dominio normativo.
- Exponer el sistema como una API REST consultable.

Desde una perspectiva organizacional, la solución propuesta contribuye a facilitar el acceso a la normativa vigente, reduciendo los tiempos de búsqueda y mejorando la interpretación de las regulaciones. Esto resulta especialmente relevante en contextos donde el cumplimiento normativo impacta directamente en la producción, la sanidad animal y la toma de decisiones en el sector agropecuario.

2. Metodología

2.1 Construcción y Análisis del Corpus

Fuentes y características

El corpus está compuesto por 10 resoluciones oficiales del SENASA obtenidas del repositorio público del organismo, cubriendo el período 2002-2025. Los documentos abordan las principales áreas de sanidad animal reguladas por el organismo:

Resolución	Año	Temática
Res. 150/2002	2002	Control de brucelosis bovina
Res. 067/2019	2019	Plan Nacional de Control y Erradicación de Brucelosis
Res. 288/2020	2020	Excepción vacunación anti aftosa (COVID-19)
Res. 767/2020	2020	Prevención Fiebre Aftosa frontera norte
Res. 542/2021	2021	Comisiones Nacionales de Sanidad y Bienestar Animal
Res. 011/2025	2025	Registro de productos veterinarios
Res. 530/2025	2025	Identificación electrónica de animales
Res. 711/2025	2025	Estrategias de vacunación anti aftosa 2025
Res. 723/2025	2025	Habilitación sanitaria medios de transporte
Res. 841/2025	2025	Norma técnica identificación electrónica

La elección de 10 documentos es suficiente para los objetivos del trabajo: demostrar y comparar enfoques de modelado. El corpus es representativo del lenguaje normativo del SENASA e incluye diversidad temática, temporal y estructural. La extensión del corpus a cientos de resoluciones es una línea de trabajo futuro que no modifica la arquitectura del sistema

2.2 Preprocesamiento

El preprocesamiento se implementó en dos etapas: extracción de texto y segmentación en chunks.

Extracción de texto (pdf_loader.py)

Se utilizó la biblioteca pdfplumber para la extracción de texto. El proceso incluye: normalización de espacios y saltos de línea, eliminación de ruidos típicos de PDFs normativos (números de página, encabezados repetidos) y preservación de la estructura de artículos. Cada documento se representa con metadatos de identificación (id, nombre, fecha, temática).

Segmentación en chunks (chunker.py)

Se adoptó una estrategia de chunking estructural adaptada al dominio normativo, en lugar del chunking por ventana de tamaño fijo convencional. Las resoluciones SENASA siguen una estructura jurídica predecible: VISTO → CONSIDERANDO → ARTÍCULOS → ANEXOS. El sistema detecta estas secciones mediante expresiones regulares y las trata como unidades semánticas naturales.

El CONSIDERANDO, que contiene los fundamentos normativos, se subdivide adicionalmente por las cláusulas “Que...”, patrón característico del estilo jurídico argentino. Las secciones largas se subdividen con overlap para no perder contexto en los bordes.

El corpus procesado resultó en **558 chunks** con los siguientes metadatos por unidad: doc_id, chunk_id, article_number, tipo_seccion, es_definicion, es_obligacion, es_prohibicion. La distribución obtenida es de

un tamaño mínimo de 15 palabras y máximo de 120, con un promedio de 79.9 y una mediana de 80.5 palabras.

Este diseño permite:

- mantener trazabilidad completa hacia el documento original.
- realizar filtrado por tipo de contenido.
- integrar eficientemente los datos con los modelos de recuperación.

Una decisión de diseño central es la regla de bypass estructural: cuando la consulta menciona un artículo específico ("artículo 3", "art. 5"), el sistema retorna directamente los chunks de ese artículo con score=1.0, sin pasar por el ranking vectorial. Esto garantiza precisión perfecta en el tipo de consulta más frecuente en el dominio normativo.

3. Modelado

3.1 Modelo clásico: TF-IDF + similitud coseno

El primer enfoque implementa un modelo clásico de recuperación de información basado en la representación TF-IDF (Term Frequency-Inverse Document Frequency). Cada chunk del corpus se vectoriza con `TfidfVectorizer` de scikit-learn, configurado con `ngram_range=(1,3)` para capturar frases normativas multipalabra, `max_df=0.9` para excluir términos omnipresentes, `min_df=1` para preservar vocabulario técnico de baja frecuencia, y una lista de stopwords personalizadas en español (ver Anexo I). La búsqueda se realiza mediante el cálculo de la similitud coseno entre el vector de la consulta y la matriz TF-IDF de los chunks.

Para garantizar precisión en la consulta de artículos, se aplicó la regla de bypass estructural mencionada en el punto anterior.

El modelo no requiere entrenamiento supervisado: el proceso de ajuste (*fit*) consiste en calcular las estadísticas TF-IDF sobre los 558 chunks del corpus y construir la matriz vectorial correspondiente. Su principal ventaja es la recuperación precisa de términos exactos, lo cual resulta especialmente relevante en textos normativos con vocabulario técnico repetitivo. Su principal limitación es la incapacidad de capturar relaciones semánticas, como sinónimos o paráfrasis.

3.2 Modelo profundo: embeddings semánticos + FAISS

El segundo enfoque reemplaza la representación dispersa de TF-IDF por vectores densos generados mediante el modelo `paraphrase-multilingual-MiniLM-L12-v2` de la librería SentenceTransformers. Este modelo fue preentrenado sobre corpus masivos multilingües y ajustado específicamente para tareas de similitud semántica entre oraciones, lo que lo hace adecuado para recuperar fragmentos de texto ante consultas formuladas en lenguaje natural. A diferencia del enfoque léxico, opera sin coincidencias exactas de términos, en su lugar, proyecta textos a un espacio vectorial continuo de 384 dimensiones donde la proximidad geométrica refleja similitud de significado.

Cada chunk del corpus y cada consulta entrante se codifican como vectores normalizados (norma L2 = 1). Esta normalización tiene una consecuencia directa en la métrica de similitud: el producto interno entre dos vectores normalizados es matemáticamente equivalente a la similitud coseno, lo que permite usar índices de producto interno sin necesidad de normalizar en tiempo de búsqueda.

Para la indexación y recuperación se utiliza FAISS con un índice `IndexFlatIP` (producto interno exacto). Esta elección es consistente con el tamaño del corpus (558 chunks), la búsqueda exacta es instantánea y no tiene sentido sacrificar precisión optando por índices aproximados como `IndexIVFFlat` o `HNSW`, que están diseñados para corpus de cientos de miles de vectores o más.

El modelo se utiliza en modo `zero-shot`, es decir, sin fine-tuning sobre el corpus SENASA. Esto implica que la representación semántica proviene íntegramente del preentrenamiento, sin adaptación al vocabulario normativo específico. Se mantiene además la misma regla estructural de bypass por artículo que en el modelo TF-IDF. Cuando la consulta referencia un artículo específico, el sistema retorna directamente los chunks correspondientes sin pasar por el ranking vectorial.

La principal ventaja de este enfoque es la capacidad de recuperar fragmentos relevantes ante reformulaciones o paráfrasis, una consulta como *"¿qué es la brucelosis?"* puede recuperar chunks que explican la enfermedad aunque no contengan esa palabra exacta. Su limitación en el dominio normativo es la tendencia a recuperar contenido semánticamente relacionado pero no textualmente preciso, lo que puede ser un problema cuando la respuesta correcta depende de la aparición de un término legal específico.

3.3 Modelo híbrido: interpolación lineal

El tercer enfoque combina las señales de los dos modelos anteriores mediante una estrategia de fusión lineal ponderada. La motivación es directa, TF-IDF es preciso ante términos exactos pero ciego a paráfrasis, mientras que los embeddings capturan similitud semántica pero pueden recuperar contenido relacionado que no es textualmente preciso. La combinación busca aprovechar las fortalezas de ambos y compensar sus limitaciones respectivas.

El score final de cada chunk se calcula como:

$$\text{score_hybrid} = \alpha \times \text{score_emb} + (1 - \alpha) \times \text{score_tfidf}$$

donde α controla el peso relativo del componente semántico. Antes de combinar, ambos scores se normalizan al rango [0, 1] mediante escalado min-max. Este paso es necesario porque los scores de TF-IDF (similitud coseno sobre vectores dispersos) y los de embeddings (producto interno sobre vectores densos normalizados) tienen distribuciones distintas; combinarlos sin normalizar introduciría un sesgo sistemático hacia el modelo con mayor escala.

El valor **α = 0.8** fue determinado ejecutando una búsqueda en grilla sobre los valores {0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8} mediante la función `optimizar_alpha()` en `test_evaluation.py`, usando MRR como métrica objetivo sobre las queries del `gold standard`. Se puede visualizar el resultado en Anexo II. Este valor implica que el componente semántico recibe cuatro veces más peso que el léxico, lo cual es

consistente con el perfil de las consultas del dominio: los usuarios suelen formular preguntas en lenguaje natural antes que reproducir términos exactos de las resoluciones.

Adicionalmente, el modelo incorpora un re-ranking heurístico basado en la estructura del corpus. Se aplican tres ajustes sobre el score combinado: los chunks identificados como ruido administrativo (encabezados institucionales, datos de expediente) reciben una penalización de 70%, lo que reduce su probabilidad de aparecer en los primeros resultados. Por otro lado, si la consulta tiene intención definicional (contiene expresiones como "qué es", "se entiende por", "significa"), los chunks clasificados como definiciones reciben un boost del 50%. De manera análoga, si la consulta refiere a requisitos o medidas obligatorias, los chunks de contenido regulatorio reciben un boost del 30%. Estas heurísticas son específica del dominio normativo y no generalizan a otros corpus.

Finalmente, se mantiene la misma regla de bypass estructural de los modelos anteriores, cuando la consulta referencia un artículo específico, el sistema retorna directamente los chunks de ese artículo sin activar el pipeline de fusión.

3.4 Módulo de pregunta-respuesta (QA)

Sobre los chunks recuperados por cualquiera de los tres retrievers, se aplica un módulo de QA que opera en tres modos:

- **Modo extractivo**: selecciona la oración con mayor overlap léxico con la consulta. Establece el baseline sin modelo neuronal.
- **Modo sintético**: combina fragmentos de los top-k chunks recuperados mediante heurísticas de concatenación. Mayor cobertura, menor precisión.
- **Modo transformer**: utiliza el modelo `mrm8488/bert-base-spanish-wwm-cased-finetuned-spa-squad2-es`, fine-tuneado sobre SQuAD 2.0 en español. Predice el span exacto (inicio y fin) dentro del contexto que responde la pregunta.

La arquitectura RAG (Retrieval-Augmented Generation) garantiza que el modelo transformer solo puede responder con información contenida en los chunks recuperados, mitigando estructuralmente el riesgo de alucinaciones.

4. Comparación de Modelos

La evaluación comparativa tiene como objetivo determinar en qué medida cada enfoque de recuperación es adecuado para el dominio normativo analizado, y en qué condiciones la combinación de señales léxicas y semánticas supera a cada componente por separado. Se evalúan los tres modelos de retrieval (TF-IDF, embeddings semánticos e híbrido) junto con los tres modos del módulo QA (extractivo, sintético y transformer) sobre un conjunto de evaluación construido específicamente para este trabajo.

Protocolo de evaluación

La evaluación se ejecuta mediante el script `run_evaluation.py`, que aplica cada modelo sobre el gold standard, calcula las métricas y exporta los resultados a la carpeta `outputs/`. Este diseño garantiza la

reproducibilidad completa del proceso: cualquier modificación al corpus o a los modelos puede re-evaluarse ejecutando un único comando.

Las métricas de retrieval calculadas son Precision@5, Recall@5, Hit Rate@5, MRR (*Mean Reciprocal Rank*) y F1@5, todas con k=5. Las métricas de QA siguen el protocolo estándar de SQuAD: Exact Match (EM) y F1 de tokens. La elección de estas métricas responde a criterios complementarios: mientras Precision y Recall capturan la cobertura y relevancia del conjunto recuperado, MRR mide la posición del primer resultado correcto, que es el dato más crítico para el módulo QA dado que utiliza el chunk mejor rankeado como contexto principal de respuesta.

Gold standard

Se construyó un gold standard de 30 consultas con los chunk_ids relevantes verificados manualmente contra el corpus (ver Anexo III). Cada consulta fue redactada para simular el lenguaje real de un usuario del sistema (profesionales o técnicos que consultan normativa SENASA) y luego contrastada contra los chunks del corpus para identificar todos los fragmentos que constituyen una respuesta válida.

Las consultas se clasificaron en tres tipos según su naturaleza lingüística, con una distribución intencional que permite atribuir diferencias de desempeño a características estructurales de cada modelo y no al azar:

- **Léxicas (9):** consultas cuyos términos clave aparecen de forma casi literal en el texto del corpus. Este tipo favorece estructuralmente a TF-IDF, dado que el matching léxico es directo.
- **Semánticas (13):** consultas formuladas mediante paráfrasis o lenguaje natural que requieren comprensión del significado más allá de la coincidencia de términos. Constituyen el escenario de mayor dificultad para el modelo clásico y el caso de uso más frecuente en un sistema de consulta real.
- **Mixtas (8):** consultas que combinan referencias a términos exactos con una intención semántica más amplia. Representan el caso donde se espera que el modelo híbrido muestre su mayor ventaja relativa.

4.1 Resultados de retrieval

Modelo	P@5	R@5	HR@5	MRR	F1@5
TF-IDF	0.187	0.558	0.733	0.484	0.259
Embeddings	0.147	0.423	0.533	0.397	0.202
Híbrido	0.207	0.593	0.800	0.561	0.284

4.2 Resultados por tipo de query

Modelo	F1 - léx	F1 - sem	F1 - mix	MRR-léx	MRR-sem	MRR-mix
TF-IDF	0.389	0.183	0.239	0.633	0.359	0.521
Embeddings	0.389	0.114	0.132	0.544	0.308	0.375

Modelo	F1 - léx	F1 - sem	F1 - mix	MRR-léx	MRR-sem	MRR-mix
Híbrido	0.389	0.250	0.222	0.633	0.471	0.625

Ver gráficos en Anexo IV

Los resultados muestran que el enfoque híbrido (α=0.8) obtuvo el mejor desempeño global, alcanzando los valores más altos en todas las métricas principales (MRR=0.561, Hit Rate@5=0.800, Recall@5=0.593 y F1=0.284). Este modelo combina eficazmente coincidencias léxicas y semánticas, destacándose especialmente en consultas semánticas (MRR=0.471 vs 0.359 TF-IDF y 0.308 embeddings) y mixtas (MRR=0.625). En consultas puramente léxicas, TF-IDF mantiene un rendimiento competitivo, igualando al híbrido.

4.3 Resultados de QA

Modelo	F1-extractivo	F1-sintético	F1-transformer
TF-IDF	0.242	0.237	0.093
Embeddings	0.247	0.201	0.084
Híbrido	0.250	0.232	0.079

En la etapa de Question Answering, los enfoques extractivos mostraron el mejor desempeño (F1≈0.25), mientras que los modelos transformer presentan resultados significativamente inferiores (F1≈0.08–0.09), con valores de Exact Match nulos en todos los casos.

4.4 Resultados de QA - RAG DistilBERT

Modelo QA	Retriever	Estrategia de contexto	F1
RAG DistilBERT	Embeddings (FAISS)	Concatenación de top-5 chunks (1 inferencia)	0.1899

El modelo RAG basado en DistilBERT, utilizando contexto concatenado, mejora respecto al transformer estándar (F1=0.1899), aunque sin superar a los métodos extractivos (ver Anexo V).

Finalmente, la validación del sistema confirmó la consistencia de las métricas, la correcta construcción del dataset y la robustez del pipeline. El proceso de optimización evidenció que el valor óptimo del parámetro α en el modelo híbrido es 0.8, maximizando el MRR.

En conjunto, los resultados indican que la combinación híbrida de retrieval junto con estrategias extractivas de QA constituye la alternativa más efectiva para este dominio.

4.5 Interpretación lingüística

El texto normativo argentino presenta características que explican los resultados observados. El vocabulario técnico altamente repetitivo del SENASA (nombres de enfermedades, procedimientos, organismos)

beneficia al TF-IDF, que captura exactamente estos términos. El híbrido no supera al TF-IDF en queries léxicas porque la señal TF-IDF ya es óptima en esos casos; su aporte real está en las queries semánticas, donde el embedding semántico captura el significado de paráfrasis como "¿qué se entiende por?" o "¿qué regula?" que no tienen correspondencia léxica directa en el texto.

Una limitación relevante es que el modelo de embeddings (MiniLM) fue preentrenado sobre corpus general y no tiene fine-tuning sobre texto jurídico en español. Un modelo ajustado específicamente para normativa argentina presumiblemente mejoraría el MRR semántico de forma significativa.

5. Implementación

5.1 Arquitectura del sistema

El sistema se estructura en tres capas con responsabilidades claramente separadas:

- **Capa de datos**: `pdf_loader.py` y `chunker.py`. Responsable de la extracción, limpieza y segmentación del corpus.
- **Capa de orquestación**: `api/pipeline.py`. Implementa el patrón `Singleton` que mantiene en memoria los modelos entrenados y coordina el flujo query → retrieval → QA.
- **Capa de transporte**: `api/main.py`. Endpoints FastAPI que exponen el sistema como API REST con esquemas Pydantic.

5.2 API REST

La API expone cinco endpoints principales:

Método	Endpoint	Descripción
GET	/estado	Estado del pipeline: documentos, chunks y modelos
POST	/buscar	Búsqueda con modelo específico (tfidf/embeddings/hybrid)
POST	/comparar	Misma query en los 3 modelos, resultados paralelos
POST	/consultar	QA completo: retrieval + respuesta en lenguaje natural
GET	/documento/{id}	Chunks de un documento específico

El endpoint/consultar acepta los parámetros modelo (tfidf - embeddings - hybrid), modo_qa (extractivo - sintetico - transformer) y top_k, permitiendo combinaciones arbitrarias para experimentación. La API se levanta con uvicorn y la documentación interactiva queda disponible automáticamente en /docs.

5.3 Reproducibilidad

El sistema incluye implementaciones mock (MockEmbeddingRetriever basado en LSA/SVD de sklearn, MockQATransformer basado en overlap léxico) que permiten correr la evaluación completa sin descargar modelos de HuggingFace. El script `run_evaluation.py` acepta el flag `--modo` con valores mock (default) o real. Los resultados del informe corresponden al modo real con los modelos neuronales completos.

6. Discusión

6.1 Alineación con objetivos organizacionales

El sistema responde a una necesidad real de las organizaciones del sector agropecuario: acceso rápido y confiable a normativa vigente. El diseño prioriza la trazabilidad (cada respuesta referencia el chunk y documento fuente) sobre la fluidez generativa, lo cual es la decisión correcta en un dominio donde una respuesta incorrecta tiene consecuencias regulatorias reales.

La métrica de negocio relevante no es el MRR sino el tiempo de resolución de consultas normativas. Un sistema que encuentra el artículo correcto en el primer resultado el 80% de las veces (HR@5=0.800) representa una mejora sustancial frente a la búsqueda manual en PDFs.

6.2 Ética y mitigación de sesgos

El sistema presenta tres vectores de riesgo ético que fueron considerados en el diseño:

- **Sesgo de corpus**: el corpus cubre sólo 10 resoluciones. Si la consulta corresponde a normativa no incluida, el sistema devolverá el chunk más similar del corpus disponible, potencialmente incorrecto. El score de relevancia devuelto en cada respuesta actúa como indicador de confianza explícito.
- **Sesgo del modelo de embeddings**: MiniLM fue preentrenado sobre corpus general con sesgos sociales conocidos. En el dominio normativo, el impacto es bajo dado el vocabulario técnico; sin embargo, no se realizó evaluación sistemática de equidad.
- **Riesgo de alucinaciones**: mitigado estructuralmente por la arquitectura RAG. El modo transformer solo puede extraer spans del contexto recuperado; no genera texto libre. El modo sintético es el de mayor riesgo de distorsión semántica al combinar fragmentos de múltiples chunks.

6.3 Limitaciones

Las limitaciones del sistema en su estado actual son las siguientes:

- **Corpus reducido** (10 resoluciones): suficiente para demostrar y comparar enfoques, pero insuficiente para cobertura operacional. La arquitectura escala sin modificaciones.
- **Sin fine-tuning en dominio**: el modelo de embeddings y el transformer BERT se usan en modo zero-shot. Un ajuste específico sobre texto jurídico argentino mejoraría las métricas semánticas.
- **Sin persistencia del índice vectorial**: FAISS se reconstruye en cada inicio. En producción convendría persistir el índice con faiss.write_index() o migrar a una base de datos vectorial (Chroma, pgvector).
- **Sin autenticación en la API**: los endpoints son públicos. En un entorno productivo se requeriría al menos autenticación por API key.

7. Conclusiones

Este trabajo presentó un sistema end-to-end de recuperación y comprensión de normativa SENASA que integra técnicas clásicas y profundas de NLP. Los resultados demuestran que el modelo híbrido (MRR=0.561) supera tanto al enfoque clásico TF-IDF (MRR=0.484) como a los embeddings puros (MRR=0.397), con la ventaja más significativa en consultas semánticas donde los embeddings aportan comprensión de paráfrasis que TF-IDF no puede capturar.

La estrategia de chunking estructural adaptada al dominio jurídico argentino, la regla de bypass por número de artículo, la arquitectura de orquestación con degradación controlada y la exposición como API REST documentada constituyen decisiones de diseño que alinean el sistema con requerimientos de producción reales. El sistema es reproducible, auditable y extensible, con una clara hoja de ruta para su evolución hacia un asistente normativo completo.

Como líneas de trabajo futuro se identifican: fine-tuning del modelo de embeddings sobre corpus jurídico en español, ampliación del corpus con la totalidad de resoluciones SENASA vigentes, incorporación de un LLM local para generación de respuestas abstractivas con control de groundedness, y evaluación de equidad del sistema ante distintas formulaciones de consultas equivalentes.

Anexos

Anexo I

```
STOPWORDS_ES = [
    "el", "la", "los", "las", "lo",
    "de", "del", "y", "a", "en",
    "que", "por", "con", "para",
    "un", "una", "unos", "unas",
    "se", "es", "son", "fue", "ser",
    "al", "como", "más", "pero", "sus", "le", "ya",
    "o", "este", "sí", "porque", "esta", "entre", "cuando",
    "muy", "sin", "sobre", "también", "me", "hasta", "hay",
    "donde", "quien", "quienes", "cual", "cuales",
    "dice", "dicen", "hacer", "hace",
]
```

Anexo II

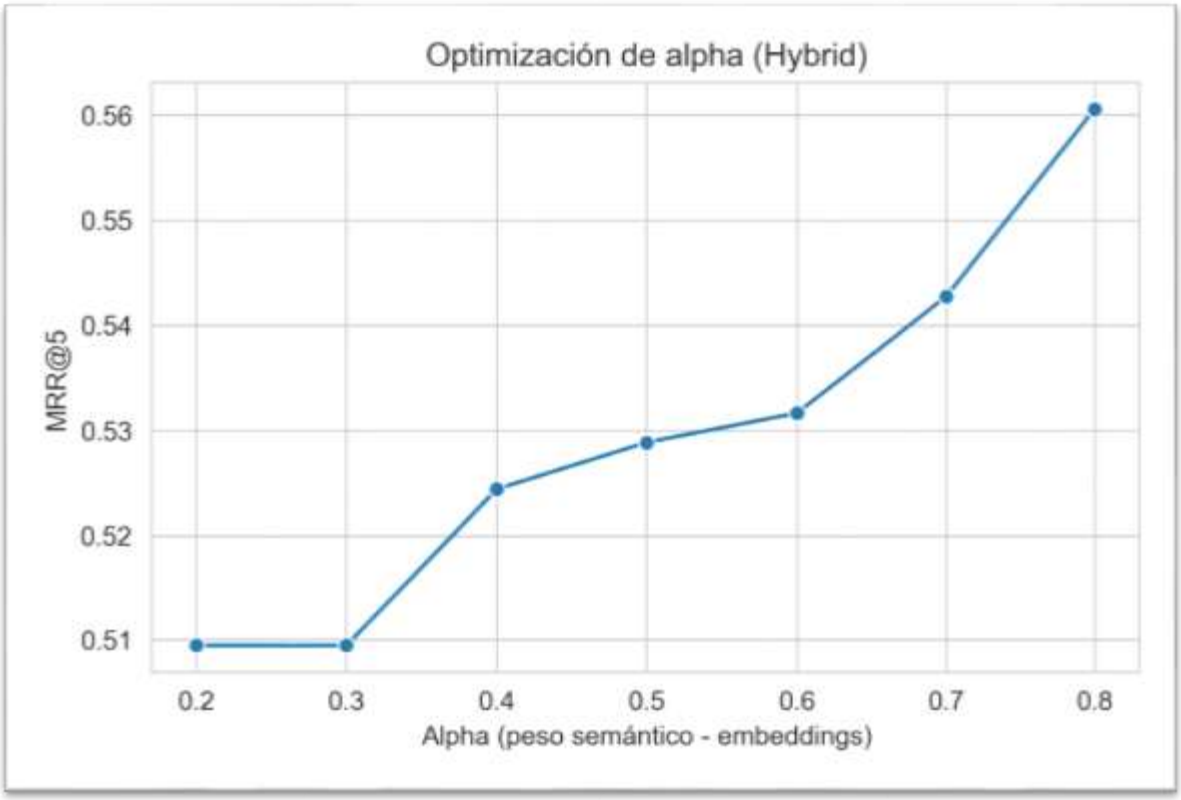

Anexo III

ID	Query	Tipo	Fuente normativa	Respuesta esperada (resumen)	Nota
Q01	¿Qué es la brucelosis bovina?	Semántica	Res_067-2019 Art. 2	Enfermedad producida por Brucella en bovinos	Definición explícita
Q02	Plan Nacional de Control y Erradicación de Brucelosis	Léxica	Res_067-2019 Art. 1	Se aprueba el plan nacional	Coincidencia literal
Q03	artículo 2 brucelosis definiciones	Léxica	Res_067-2019 Art. 2	Definiciones del artículo	Activa regla por artículo
Q04	¿Qué se entiende por producto veterinario?	Semántica	Res_011-2025 Art. 12	Sustancia para prevención/diagnóstico/tratamiento	Paráfrasis
Q05	identificación electrónica obligatoria ganado bovino	Mixta	Res_841-2025 / Res_530-2025	Norma de identificación electrónica	Multi-doc
Q06	estrategias de vacunación antiaftosa 2025	Léxica	Res_711-2025 Art. 1	Estrategias de vacunación	Coincidencia literal
Q07	normativa transporte animales vivos	Semántica	Res_723-2025 Art. 1	Norma de habilitación sanitaria	Paráfrasis
Q08	comisiones sanidad animal creación	Mixta	Res_542-2021 Art. 1	Creación de comisiones	Intención + términos
Q09	prevención fiebre aftosa frontera norte	Léxica	Res_767-2020 Art. 1	Medidas de prevención	Coincidencia directa
Q10	excepción vacunación aftosa COVID	Semántica	Res_288-2020 Art. 1	Excepción a vacunación	Contexto implícito
Q11	artículo 1 resolución 530 identificación	Léxica	Res_530-2025 Art. 1	Sistema de identificación	Query estructural
Q12	requisitos registrar empresa veterinaria	Semántica	Res_011-2025 Art. 3	Inscripción obligatoria	Procedimiento
Q13	objetivo comisiones sanidad animal	Mixta	Res_542-2021 Art. 2	Espacio participativo	Mezcla semántica
Q14	vacunación antibrucélica obligatoria	Léxica	Res_150-2002	Certificación sanitaria	Histórica
Q15	animales identificación electrónica	Semántica	Res_841-2025 / 530-2025	Bovinos, bubalinos, cérvidos	Multi-doc
Q16	definicion producto veterinario	Semántica	Res_011-2025	Sustancia para tratamiento	Paráfrasis simple
Q17	animal reaccionante positivo	Semántica	Res_067-2019 Art. 2	Animal positivo a pruebas	Definición
Q18	producto biologico veterinario	Semántica	Res_011-2025	Producto de origen biológico	Subtipo
Q19	artículo 3 resolución 067	Léxica	Res_067-2019 Art. 3	Medidas SENASA	Estructural
Q20	artículo 20 resolución 011	Léxica	Res_011-2025 Art. 20	Calidad de productos	Estructural

Q21	artículo 88 resolución 011	Léxica	Res_011-2025 Art. 88	Régimen sancionatorio	Estructural
Q22	obligaciones productores brucelosis	Mixta	Res_067-2019	Vacunación obligatoria	Normativa
Q23	medidas sanitarias brucelosis	Mixta	Res_067-2019	Restricciones sanitarias	Multi-chunk
Q24	requisitos producto no biologico	Mixta	Res_011-2025 Art. 18	Documentación requerida	Específico
Q25	como registrar producto veterinario	Semántica	Res_011-2025 Arts. 18-19	Procedimiento de registro	Multi-chunk
Q26	inscripción proveedores dispositivos	Semántica	Res_530-2025 / 011-2025	Registro obligatorio	Multi-doc
Q27	brucelosis bovina enfermedad	Semántica	Res_067-2019	Enfermedad infecciosa	Query coloquial
Q28	importancia sanidad animal argentina	Semántica	Res_011-2025 / 723-2025	Impacto productivo	Conceptual
Q29	control enfermedades animales	Mixta	Múltiples resoluciones	Programas sanitarios	Amplia
Q30	identificacion animal trazabilidad	Mixta	Res_530-2025	Trazabilidad ganadera	Sistema

Anexo IV

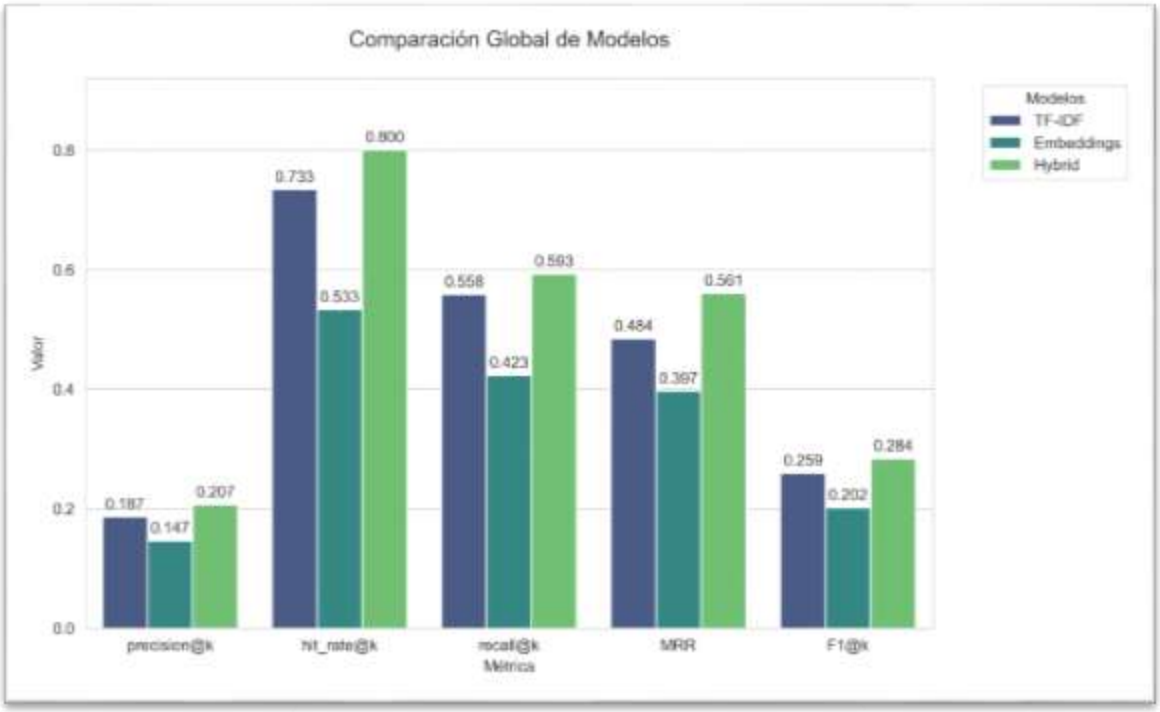

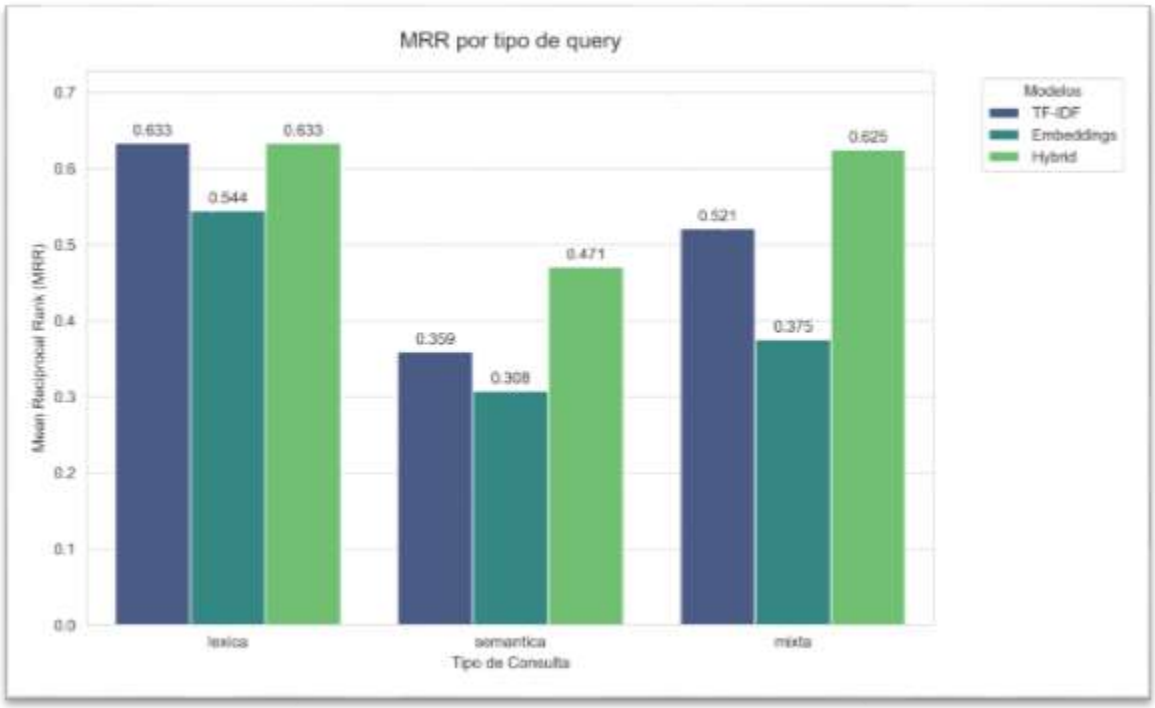

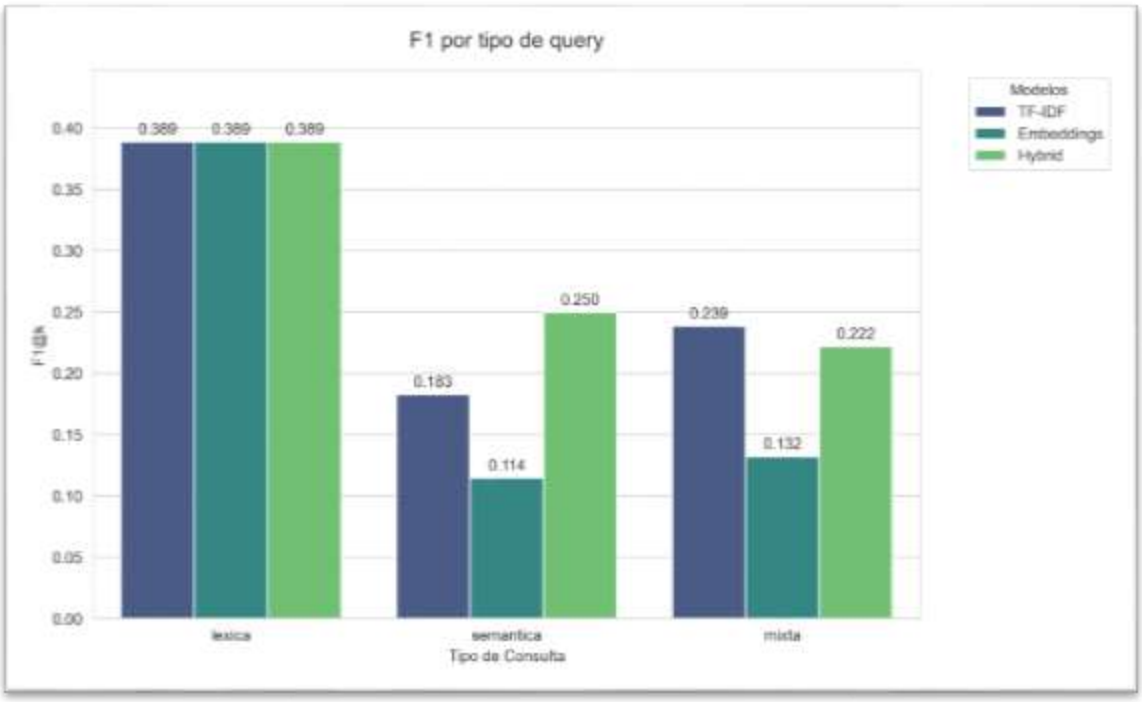

Anexo V

RAG DistilBERT - Resultados por query

ID	Query	Tipo	F1	EM
Q01	¿Qué es la brucelosis bovina?	semántica	0.286	0
Q02	Plan Nacional de Control y Erradicación de Brucelosis	léxica	0.377	0
Q03	artículo 2 brucelosis definiciones	léxica	0.125	0

Q04	¿Qué se entiende por producto veterinario?	semántica	0.222	0
Q05	identificación electrónica obligatoria ganado bovino	mixta	0.182	0
Q06	estrategias de vacunación antiaftosa para bovinos 2025	léxica	0.286	0
Q07	¿Qué regula la normativa de transporte de animales vivos?	semántica	0.222	0
Q08	comisiones nacionales de sanidad animal creación	mixta	0.200	0
Q09	prevención fiebre aftosa frontera norte Argentina	léxica	0.250	0
Q10	excepción vacunación aftosa por pandemia COVID	semántica	0.182	0
Q11	artículo 1 resolución 530 identificación electrónica	léxica	0.167	0
Q12	requisitos para registrar empresa elaboradora productos veterinarios	semántica	0.154	0
Q13	objetivo comisiones sanidad bienestar animal	mixta	0.200	0
Q14	vacunación antibrucélica obligatoria hembras bovinas	léxica	0.143	0
Q15	¿Qué animales deben ser identificados electrónicamente?	semántica	0.167	0
Q16	definicion producto veterinario	semántica	0.222	0
Q17	que es un animal reaccionante positivo	semántica	0.333	0
Q18	definicion producto biologico veterinario	semántica	0.154	0
Q19	articulo 3 resolucion 067 brucelosis	léxica	0.200	0
Q20	articulo 20 resolucion 011 productos veterinarios	léxica	0.286	0
Q21	articulo 88 resolucion 011	léxica	0.500	0
Q22	obligaciones de los productores bovinos brucelosis	mixta	0.182	0
Q23	medidas sanitarias obligatorias brucelosis	mixta	0.100	0
Q24	requisitos para registrar producto veterinario no biologico	mixta	0.167	0
Q25	como solicitar el registro de un producto veterinario	semántica	0.154	0
Q26	inscripcion obligatoria proveedores senasa dispositivos identificacion	semántica	0.000	0
Q27	brucelosis bovina que es enfermedad	semántica	0.222	0
Q28	por que es importante la sanidad animal en argentina	semántica	0.133	0
Q29	control y erradicacion de enfermedades animales	mixta	0.154	0
Q30	identificacion animal trazabilidad ganaderia	mixta	0.182	0
	Promedio		**0.190**	**0.0**

El EM=0 en todos los casos es esperable, el modelo extrae spans cortos y exactos del texto que raramente coinciden token a token con las respuestas gold redactadas como frases completas. El retriever usado es EmbeddingRetriever (SentenceTransformer + FAISS), top_k=5, contexto concatenado truncado a 1800 caracteres.